Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer e-ISSN: 2548-964X
Vol. 10, No. 1, Januari 2026, hlm. x-x http://j-ptiik.ub.ac.id

Analisis Perbandingan Metode Chunking dalam Chatbot Berbasis Retrieval-Augmented Generation Rekomendasi Terapi Nutrisi Medis Pasien

Eleazar Tadeo Eman[1], Tirana Noor Fatyanosa[2], Alham Fikri Aji[3]

Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya
Email: [1]eleazartadeo@ub.ac.id, [2]fatyanosa@ub.ac.id, [3]alham.fikri@mbzuai.ac.ae

Abstrak

Chatbot berbasis kecerdasan buatan semakin banyak digunakan dalam layanan kesehatan, namun akurasi respons sering bergantung pada kualitas proses retrieval dalam sistem Retrieval-Augmented Generation (RAG). Penelitian ini membandingkan tiga metode *chunking* yaitu *recursive chunking*, *semantic chunking*, dan *Double Pass Merging Chunking* pada *chatbot* RAG untuk rekomendasi terapi nutrisi medis pasien. Pengujian dilakukan menggunakan dataset laporan nutrisi medis dan dievaluasi dengan BLEU, ROUGE, serta metrik RAGAS seperti *context precision*, *context recall*, *faithfulness*, dan *answer relevancy*. Hasil analisis menunjukkan bahwa *Double Pass Merging Chunking* memberikan performa terbaik pada 7 dari 8 metrik evaluasi dengan nilai *Context Precision* (0,5514), *Context Recall* (0,2721), *Faithfulness* (0,2381), BLEU (0,9129), ROUGE-1 (0,1117), ROUGE-2 (0,0174), dan ROUGE-L (0,0680). *Semantic chunking* menunjukkan peningkatan signifikan pada *Context Recall* (0,2702) dengan selisih 48% dibandingkan *recursive chunking*. Temuan ini menegaskan bahwa pemilihan metode *chunking* berpengaruh signifikan terhadap kualitas rekomendasi nutrisi medis yang dihasilkan *chatbot* berbasis RAG.

Kata kunci: *natural language processing, large language model, retrieval-augmented generation, chatbot nutrisi medis, chunking, BLEU, ROUGE, RAGAS*

Abstract

Artificial intelligence chatbots are increasingly used in healthcare services, yet the accuracy of their responses depends greatly on the effectiveness of the retrieval process in Retrieval-Augmented Generation (RAG) systems. This study compares three chunking methods: recursive chunking, semantic chunking, and Double Pass Merging Chunking, within a RAG-based chatbot designed to deliver medical nutrition therapy recommendations. The evaluation uses a dataset of medical nutrition reports and applies BLEU, ROUGE, and RAGAS metrics such as context precision, context recall, faithfulness, and answer relevancy. The analysis results show that Double Pass Merging Chunking delivers the best performance across 7 out of 8 evaluation metrics, achieving the highest scores in Context Precision (0.5514), Context Recall (0.2721), Faithfulness (0.2381), BLEU (0.9129), ROUGE-1 (0.1117), ROUGE-2 (0.0174), and ROUGE-L (0.0680). Semantic Chunking showed significant improvement in Context Recall (0.2702) with a 48% difference compared to Recursive Chunking. These findings highlight the substantial impact of chunking strategy selection on the accuracy of medical nutrition recommendations produced by RAG-based chatbots.

Keywords: *natural language processing, large language model, retrieval-augmented generation, medical nutrition chatbot, chunking, BLEU, ROUGE, RAGAS*

1. PENDAHULUAN

Dalam era digital dan kemajuan teknologi kecerdasan buatan, *chatbot* semakin banyak digunakan oleh masyarakat dengan pengguna ChatGPT mencapai 4,6 miliar pengguna global dan 127 juta di Indonesia (Semrush, 2025). *Chatbot* dapat digunakan untuk berbagai sektor termasuk kesehatan (Bachri dkk., 2024). Namun dalam domain medis, akurasi sangat penting karena Large Language Model (LLM) rentan mengalami halusinasi seperti diagnosis diferensial yang mengandung bias (Wang &

Zhang, 2024).

Retrieval-Augmented Generation (RAG) adalah teknik yang menggabungkan pengambilan informasi dengan model bahasa generatif untuk meningkatkan akurasi dan mengurangi halusinasi (Li dkk., 2025). Namun kualitas respons *chatbot* RAG sangat bergantung pada metode *chunking* yang digunakan untuk memecah dokumen menjadi bagian-bagian kecil sebelum diproses (Fanani, 2025).

Penelitian sebelumnya menggunakan metode *chunking* konvensional seperti fixed-size *chunking* dan *recursive chunking* (Mondillo dkk., 2025). Namun belum ada penelitian yang membandingkan metode *chunking* canggih seperti *Double Pass Merging Chunking* dalam konteks rekomendasi medis. Penelitian ini membandingkan tiga metode *chunking* (*recursive chunking*, *semantic chunking*, dan *Double Pass Merging Chunking*) dalam *chatbot* RAG untuk rekomendasi terapi nutrisi medis guna menentukan metode yang paling efektif dalam meningkatkan kualitas respons.

2. LANDASAN KEPUSTAKAAN

2.1. Penelitian Terdahulu

Beberapa penelitian menunjukkan bahwa strategi *chunking* berpengaruh signifikan terhadap performa sistem Retrieval-Augmented Generation (RAG). Perbandingan antara character-based, recursive, dan *semantic chunking* pada dokumen keuangan dan menemukan bahwa *recursive chunking* memberikan akurasi tinggi dengan konsekuensi efisiensi yang lebih rendah (Saelemyr & Femdal, 2024). Pada domain pendidikan, kombinasi *recursive chunking* dengan hybrid retrieval menghasilkan performa kompetitif (Khasanova Zafar kizi & Suh, 2025). Sementara itu, *semantic chunking* hanya efektif pada dataset tertentu dan tidak konsisten di semua skenario (Qu dkk., 2025). Metode *Double Pass Merging Chunking* yang menerapkan penggabungan semantik bertahap terbukti mampu meningkatkan performa RAG, namun belum diuji pada domain kesehatan (Gong dkk., 2024). Berdasarkan hal tersebut, belum terdapat penelitian yang secara langsung membandingkan *recursive chunking*, *semantic chunking*, dan *Double Pass Merging Chunking* dalam *chatbot* RAG untuk rekomendasi terapi nutrisi medis menggunakan kombinasi metrik RAGAS, BLEU, dan ROUGE, sehingga penelitian ini dilakukan untuk mengisi celah tersebut.

2.2. Retrieval-Augmented Generation

RAG adalah pendekatan AI yang meningkatkan model bahasa generatif dengan mengintegrasikan informasi spesifik domain dari basis data eksternal (Heredia Álvaro & Barreda, 2025). Sistem RAG memungkinkan spesialisasi domain tanpa memodifikasi parameter internal model melalui pendekatan augmentasi eksternal yang dapat diakses dengan sumber daya terbatas.

2.3. Strategi Chunking

Chunking adalah proses memecah dokumen menjadi segmen teks yang lebih kecil untuk tugas Information Retrieval. Dalam konteks LLM dan RAG, *chunking* diperluas untuk mencakup transformasi dokumen yang mempertahankan informasi semantik dari dokumen asli (Brådland dkk., 2025). Proses *chunking* diatur oleh tiga prinsip inti yaitu setiap *chunk* harus menyampaikan satu konsep inti, *chunk* harus semantik independen, dan kumpulan *chunk* harus mempertahankan seluruh konten semantik dokumen sumber.

2.3.1. Recursive Chunking

Recursive chunking menggunakan daftar hierarkis pemisah yang telah ditentukan sebelumnya seperti paragraf, kalimat, kata untuk memecah teks menjadi potongan yang lebih koheren dengan mengikuti pemisahan alami dalam konten (IBM, 2025).

2.3.2. Semantic Chunking

Semantic chunking adalah proses pembagian teks menjadi bagian yang koheren secara semantik bukan berdasarkan panjang tetap. Pendekatan ini mengelompokkan kalimat yang memiliki keterkaitan makna menjadi satu kesatuan (Alammar dkk., 2025).

2.3.3. Double Pass Merging Chunking

Double Pass Merging Chunking adalah algoritma *semantic chunking* yang bekerja dalam dua tahap untuk menangani teks kompleks. Pass pertama menggabungkan kalimat menjadi *chunk* awal berdasarkan kesamaan kosinus, sedangkan pass kedua menyempurnakan *chunk* dengan memeriksa pasangan atau tripel *chunk* yang berurutan (Gong dkk., 2024).

2.4. BLEU

BLEU (BiLingual Evaluation Understudy) adalah metrik untuk mengevaluasi kualitas kalimat yang dihasilkan mesin dengan membandingkannya terhadap kalimat referensi menggunakan kombinasi uni-gram, bi-gram, dan n-gram tingkat lebih tinggi (Khurana dkk., 2023). Adapun persamaan dari BLEU dapat dilihat pada persamaan 2.1 (GeeksforGeeks, 2025a).

$$BLEUScore = BP * \exp\left(\sum_{i=1}^{N} w_i * \ln(p_i)\right) \quad (2.1)$$

Dimana:

- BP adalah *Brevity Penalty*. Untuk rumus dari BP dapat dilihat pada persamaan 2.3
- w_i adalah bobot untuk presisi *n-gram* pada orde ke-i (biasanya bobotnya sama untuk semua nilai *i*).
- p_i adalah skor presisi *n-gram* termodifikasi pada orde ke-i. Merujuk ke persamaan 2.2
- N adalah orde *n-gram* maksimum yang dipertimbangkan (biasanya hingga orde 4).

$$p_i = \frac{Count\ Clip(matches_i, max-ref-count_i)}{candidate-n-grams_i} \quad (2.2)$$

Dimana:

- Count Clips adalah fungsi yang membatasi (*clipping*) jumlah *n-gram* yang cocok ($matches_i$) dengan jumlah maksimum kemunculan *n-gram* tersebut di seluruh terjemahan referensi ($max\text{-}ref\text{-}count_i$).
- $matches_i$ adalah jumlah *n-gram* orde ke-*i* yang cocok secara persis antara terjemahan kandidat dan salah satu terjemahan referensi.
- $max\text{-}ref\text{-}count_i$ adalah jumlah kemunculan maksimum dari *n-gram* spesifik orde ke-*i* yang ditemukan dalam satu terjemahan referensi.
- $candidate\text{-}n\text{-}grams_i$ adalah jumlah total *n-gram* orde ke-*i* yang terdapat dalam terjemahan kandidat.

$$BP = \exp\left(1 - \frac{r}{c}\right) \quad (2.3)$$

Dimana:

- r adalah panjang terjemahan kandidat.
- c adalah panjang rata-rata dari terjemahan referensi.

2.5. ROUGE

ROUGE (Recall-Oriented Understudy for Gisting Evaluation) adalah paket evaluasi otomatis untuk menilai kualitas ringkasan dengan mengukur tumpang tindih antara ringkasan kandidat dan referensi melalui co-occurrence n-gram, longest common subsequences, dan kecocokan skip-bigram (Lin, 2004). Adapun rumus dari ROUGE-N dapat dilihat pada persamaan 2.4 dan rumus dari ROUGE-L dapat dilihat pada persamaan 2.5 (GeeksforGeeks, 2025b).

$$ROUGE - N = \frac{Jumlah\ n-gram\ yang\ cocok}{Total\ n-gram\ dalam\ terjemahan\ referensi} \quad (2.4)$$

$$ROUGE - L = F_\beta = \frac{(1+\beta^2) \cdot P \cdot R}{\beta^2 \cdot P + R} \quad (2.5)$$

Dimana:

- P adalah *precision*
- R adalah *recall*
- β biasanya bernilai 1

2.6. RAGAS

RAGAS (Retrieval Augmented Generation Assessment) adalah framework untuk mengevaluasi pipeline RAG yang mengukur *Faithfulness*, Answer Relevance, Context Relevance, *Context Precision*, dan *Context Recall* menggunakan pemodelan LLM (Es dkk., 2024).

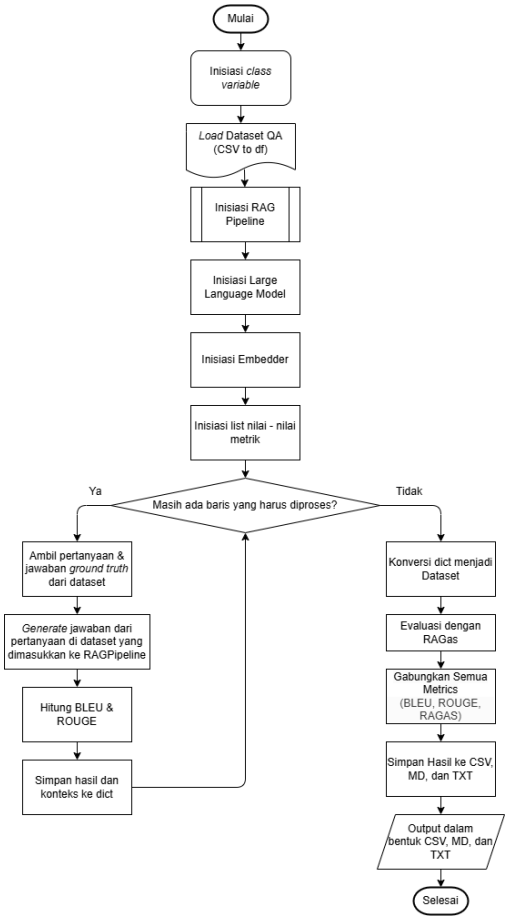
3. METODOLOGI PENELITIAN

Penelitian ini merupakan penelitian nonimplementatif analitik dengan pendekatan studi komparatif. Objek penelitian adalah tiga metode *chunking* yang dibandingkan yaitu *recursive chunking*, *semantic chunking*, dan *Double Pass Merging Chunking*. Dataset yang digunakan bersumber dari laporan Praktik Kerja Profesi Program Studi Profesi Dietisien Fakultas Ilmu Kesehatan Universitas Brawijaya tahun 2021 hingga 2023.

Sistem *chatbot* RAG dikembangkan menggunakan model embeddinggemma dan generator GPT-OSS dengan Qdrant sebagai *vector store*. Setiap metode *chunking* diimplementasikan dengan chunk_size=1000

karakter. Evaluasi dilakukan menggunakan metrik BLEU, ROUGE-1, ROUGE-2, ROUGE-L untuk mengukur kesamaan teks, serta metrik RAGAS (*Context Precision*, *Context Recall*, *Faithfulness*, *Answer Relevancy*) untuk mengukur kualitas retrieval dan generasi.

Seperti yang tertera pada Gambar 3.1, proses pengujian dilakukan dengan mengambil pertanyaan dari dataset, menghasilkan jawaban menggunakan pipeline RAG dengan masing-masing metode *chunking*, kemudian menghitung skor metrik evaluasi dengan membandingkan jawaban yang dihasilkan terhadap *ground truth*. Hasil evaluasi disimpan dalam format CSV, *Markdown File*, dan TXT untuk analisis lebih lanjut.



Gambar 3.1 Alur pengujian

4. HASIL DAN PEMBAHASAN

4.1. Perbandingan Metode *Chunking*

Tabel 1 menunjukkan hasil perbandingan ketiga metode *chunking* berdasarkan delapan metrik evaluasi.

Tabel 1. Hasil Perbandingan Metode *Chunking*

Metrik	Recursive	Semantic	Doublepass
BLEU	0,8136	0,8731	**0,9129**
ROUGE-1	0,1071	0,1104	**0,1117**
ROUGE-2	0,0160	0,0169	**0,0174**
ROUGE-L	0,0641	0,0666	**0,0680**
Context Precision	0,5319	0,5328	**0,5514**
Context Recall	0,1830	0,2702	**0,2721**
Faithfulness	0,1609	0,2347	**0,2381**
Answer Relevancy	**0,6145**	0,6078	0,6061

Double Pass Merging Chunking menunjukkan performa terbaik pada 7 dari 8 metrik evaluasi. Metode ini mencatat skor tertinggi pada *Context Precision* (0,5514), *Context Recall* (0,2721), dan *Faithfulness* (0,2381), yang menunjukkan efektivitas dalam mengambil konteks relevan dan menghasilkan jawaban konsisten dengan informasi faktual. Pada metrik kesamaan teks, Doublepass juga unggul dengan skor BLEU tertinggi (0,9129), ROUGE-1 (0,1117), ROUGE-2 (0,0174), dan ROUGE-L (0,0680).

Semantic Chunking menempati posisi kedua dengan peningkatan signifikan pada *Context Recall* (0,2702) dibandingkan *Recursive Chunking* (0,1830), dengan selisih hampir 48%. Hal ini menunjukkan *Semantic Chunking* lebih baik dalam menangkap konteks relevan dari dokumen medis yang kompleks.

Recursive Chunking mencatat performa terendah di sebagian besar metrik, terutama pada *Context Recall* (0,1830) dan *Faithfulness* (0,1609). Meskipun demikian, metode ini sedikit unggul pada *Answer Relevancy* (0,6145) dengan selisih 0,0084 poin. Keunggulan tipis ini terjadi karena *recursive chunking* menghasilkan *chunk* yang lebih pendek dan spesifik, memudahkan sistem retrieval menemukan informasi yang langsung cocok dengan pertanyaan user.

4.2. Analisis Hasil *Chunking*

Recursive chunking menunjukkan pemotongan teks yang tidak memperhatikan struktur logis dokumen. *Chunk* yang dihasilkan terpotong secara arbitrary, misalnya "NI-2.1 Asupan makanan dan" yang terpotong di tengah kalimat. Terdapat juga pengulangan konten yang sama pada beberapa pertanyaan berbeda dan ketidakkonsistenan dalam mempertahankan konteks pasien.

Semantic chunking menghasilkan *chunk* yang lebih koheren secara kontekstual. *Chunk* pertama selalu memuat identitas pasien yang lengkap dan terstruktur, diikuti dengan bagian assessment yang utuh. Tidak ada pengulangan *chunk* yang tidak perlu dan setiap *chunk*

memiliki konteks yang jelas. Namun pada beberapa kasus, *chunk* terlalu pendek dan berdiri sendiri padahal bisa digabung dengan konteks yang lebih luas.

Double Pass Merging Chunking menunjukkan keseimbangan optimal antara kelengkapan informasi dan ukuran *chunk*. *Chunk* yang dihasilkan memuat identitas pasien lengkap dengan struktur yang rapi dan konsisten. Metode ini mampu menggabungkan informasi terkait seperti data antropometri spesifik dengan konteks pasien yang jelas. Tidak ditemukan *chunk* yang terpotong di tengah kalimat atau diagnosis, dan setiap *chunk* memiliki nilai informasi substansial yang dapat dipahami secara mandiri.

5. KESIMPULAN DAN SARAN

Berdasarkan hasil evaluasi menggunakan metrik RAGAS dan kesamaan teks, *Double Pass Merging Chunking* terbukti sebagai metode paling efektif untuk *chatbot* RAG rekomendasi terapi nutrisi medis dengan skor tertinggi pada *Context Precision* (0,5514), *Context Recall* (0,2721), *Faithfulness* (0,2381), BLEU (0,9129), dan seluruh metrik ROUGE. *Semantic chunking* menempati posisi kedua dengan peningkatan signifikan pada *Context Recall* (0,2702) dibandingkan *Recursive Chunking* (0,1830). *Recursive Chunking* mencatat performa terendah di sebagian besar metrik. Keunggulan *Double Pass Merging Chunking* terletak pada kemampuannya mempertahankan konteks relevan dan struktur informasi medis secara koheren.

Penelitian selanjutnya dapat memperluas pendekatan dengan menambahkan metode *chunking* lainnya seperti *Document Based Chunking* atau *Agentic Chunking*, menggunakan dataset yang lebih besar dan beragam, mengevaluasi performa model yang telah di-*fine tuning* untuk domain kesehatan, serta memberikan *prompt engineering* yang tepat berdasarkan hasil penelitian ini.

6. DAFTAR PUSTAKA

Alammar, M., El Hindi, K., & Al-Khalifa, H. (2025). English-Arabic Hybrid Semantic Text Chunking Based on Fine-Tuning BERT. *Computation*, *13*(6). https://doi.org/10.3390/computation13060151

Bachri, B., Muthmainnah, A., Juliani, C., Qonitatunnajah, M., & Wicaksono, W. (2024). SCOPING REVIEW: TEKNOLOGI BERBASIS ARTIFICIAL INTELLIGENCE DALAM MENCEGAH SUICIDE IDEATION GENERASI Z INDONESIA. Dalam *Jurnal Empati* (Vol. 13).

Brådland, H., Goodwin, M., Andersen, P. A., Nossum, A. S., & Gupta, A. (2025). A New HOPE: Domain-agnostic Automatic Evaluation of Text Chunking. *SIGIR 2025 - Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 170–179. https://doi.org/10.1145/3726302.3729882

Es, S., James, J., Espinosa Anke, L., & Schockaert, S. (2024). RAGAs: Automated Evaluation of Retrieval Augmented Generation. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, 150–158. https://doi.org/10.18653/v1/2024.eacl-demo.16

Fanani, I. (2025). IMPLEMENTASI RETRIEVAL AUGMENTED GENERATION UNTUK EVALUASI PROPOSAL TUGAS AKHIR MAHASISWA. Dalam *Ikhsan Fanani 1 Jurnal Teknologi Komputer dan Informatika* | (Vol. 3, Nomor 2).

GeeksforGeeks. (2025a, Juli 23). *NLP - BLEU Score for Evaluating Neural Machine Translation - Python - GeeksforGeeks*. https://www.geeksforgeeks.org/nlp/nlp-bleu-score-for-evaluating-neural-machine-translation-python/

GeeksforGeeks. (2025b, Juli 23). *Understanding BLEU and ROUGE score for NLP evaluation - GeeksforGeeks*. https://www.geeksforgeeks.org/nlp/understanding-bleu-and-rouge-score-for-nlp-evaluation/

Gong, X., He, R., & Peng, Q. (2024). Reordering of Double Pass Merging Chunking to Improve Retrieval Augmented Generation. *Proceedings - 2024 3rd International Conference on Computer Applications Technology, CCAT 2024*, 68–78. https://doi.org/10.1109/CCAT64370.2024.00021

Heredia Álvaro, J. A., & Barreda, J. G. (2025). An advanced retrieval-augmented generation system for manufacturing quality control. *Advanced Engineering*

Informatics, *64*. https://doi.org/10.1016/j.aei.2024.103007

IBM. (2025). *What Is Agentic Chunking?* https://www.ibm.com/think/topics/agentic-chunking

Khasanova Zafar kizi, M., & Suh, Y. (2025). Design and Performance Evaluation of LLM-Based RAG Pipelines for Chatbot Services in International Student Admissions. *Electronics*, *14*(15), 3095. https://doi.org/10.3390/electronics14153095

Khurana, D., Koli, A., Khatter, K., & Singh, S. (2023). Natural language processing: state of the art, current trends and challenges. *Multimedia Tools and Applications*, *82*(3), 3713–3744. https://doi.org/10.1007/s11042-022-13428-4

Li, Z., Wang, Z., Wang, W., Hung, K., Xie, H., & Wang, F. L. (2025). Retrieval-augmented generation for educational application: A systematic survey. Dalam *Computers and Education: Artificial Intelligence* (Vol. 8). Elsevier B.V. https://doi.org/10.1016/j.caeai.2025.100417

Lin, C.-Y. (2004). *ROUGE: A Package for Automatic Evaluation of Summaries*.

Mondillo, G., Colosimo, S., Perrotta, A., Frattolillo, V., Masino, M., Martino, M., Miraglia del Giudice, E., & Marzuillo, P. (2025). Artificial intelligence for solving pediatric clinical cases: A Retrieval-Augmented approach utilizing Llama3.2 and structured references. *International Journal of Medical Informatics*, *203*. https://doi.org/10.1016/j.ijmedinf.2025.106027

Qu, R., Tu, R., & Bao, F. S. (2025). Is Semantic Chunking Worth the Computational Cost? *Findings of the Association for Computational Linguistics: NAACL 2025*, 2155–2177. https://doi.org/10.18653/v1/2025.findings-naacl.114

Saelemyr, J., & Femdal, H. (2024). *Chunk Smarter, Retrieve Better: Enhancing LLMs in Finance An Empirical Comparison of Chunking Techniques in Retrieval Augmented Generation for Financial Reports*.

Semrush. (2025). *Top Websites in the World - June 2025 Most Visited & Popular Rankings*. https://www.semrush.com/website/top/

Wang, D., & Zhang, S. (2024). Large language models in medical and healthcare fields: applications, advances, and challenges. *Artificial Intelligence Review*, *57*(11). https://doi.org/10.1007/s10462-024-10921-0